GUÍA DE IMPLEMENTACIÓN · OCTUBRE 2026

# IA abierta e híbrida, de la cámara a la frontera

Cuatro capas y un orquestador: Qwen en casa, DeepSeek en casa o vía API, y la frontera solo cuando vale la pena

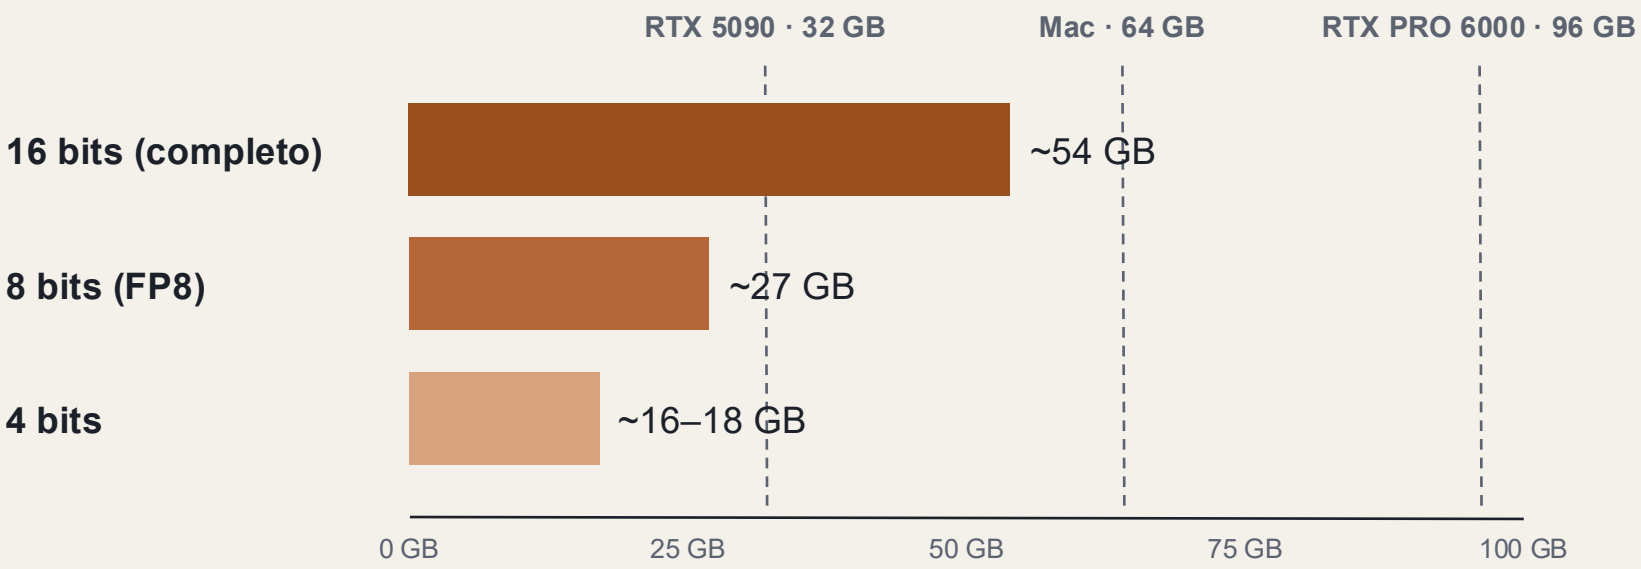



Marcelo José Rovai · UNIFEI · AIEng4D

# Concepto 1 · ¿Cabe el modelo? Parámetros × precisión

Memoria ≈ parámetros × bytes por parámetro + caché de las conversaciones

**EJEMPLO: QWEN3.8 27B (DENSO)**




### Cuantizar

Bajar de 16 a 8 o 4 bits reduce la memoria a la mitad o a un cuarto y acelera la escritura, con alguna pérdida de calidad.

### No solo los pesos

Cada conversación necesita memoria libre para su caché (concepto 4).

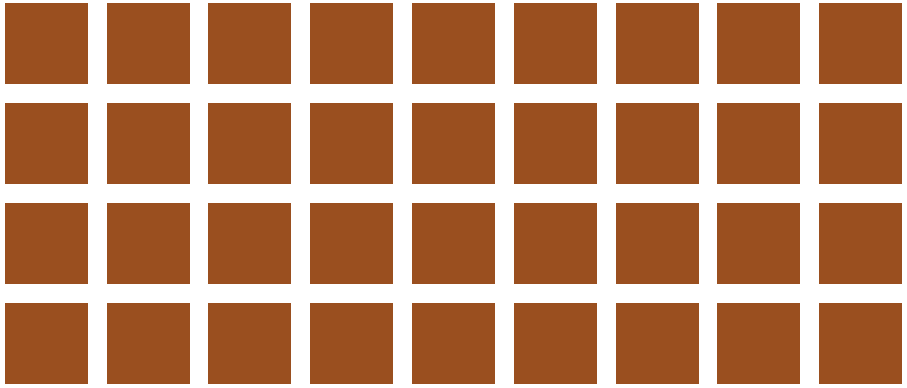
*Regla práctica: mil millones de parámetros ≈ 2 GB en 16 bits, 1 GB en 8 bits y ~0,6 GB en 4 bits.*

Tamaños aproximados, solo pesos · Qwen3.8 27B en 8 bits: ~27 GB (video «Mac Studio vs NVIDIA RTX», oct 2026)

# Concepto 2 · Modelo denso o mezcla de expertos (MoE)

DENSO

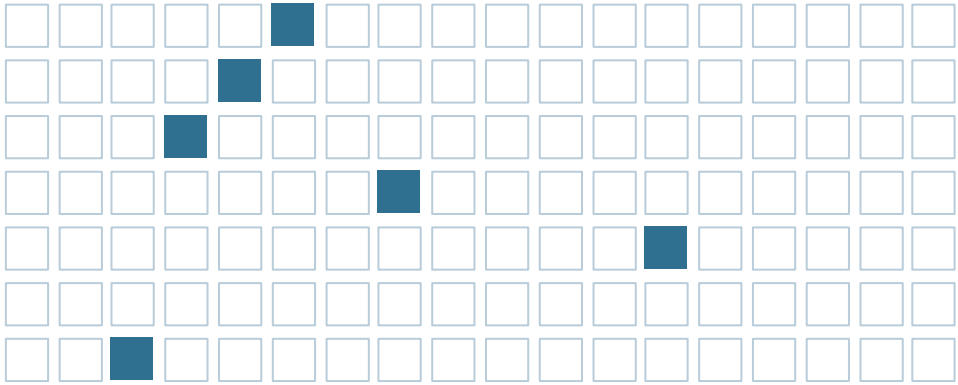
## Qwen3.8 27B



27 mil millones de parámetros, todos activos en cada token

MEZCLA DE EXPERTOS (MOE)

## DeepSeek V4.1 Flash



552 mil millones en total; cada token pasa por 6 de 384 expertos en cada capa: ~16 mil millones activos

La memoria depende del total

La velocidad, de los activos

El token siguiente elige otros expertos: por eso todos deben estar cargados en memoria

# Concepto 3 · Leer y escribir: prefill y decode

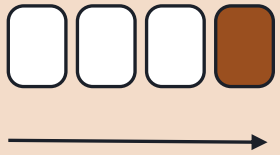


PREFILL

## Leer

Procesa todo el contexto: instrucciones, documentos e historial.

**Lo limita el cómputo (TFLOPS): gana la GPU**



DECODE

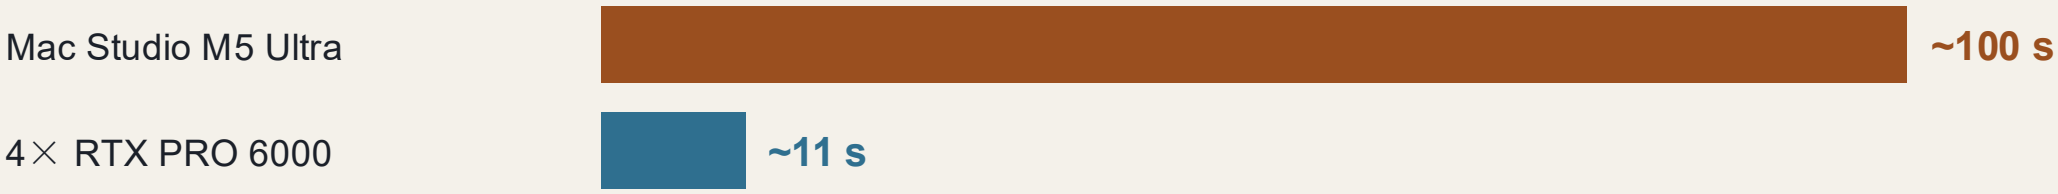
## Escribir

Genera token por token; para cada uno lee todos los pesos.

**Techo teórico: 1.792 GB/s ÷ 27 GB ≈ 66 tok/s**

MTP (predicción de varios tokens) y la decodificación especulativa pueden superarlo: proponen varios tokens y los verifican de una vez.

**Leer 100.000 tokens antes de la primera palabra**




*Un agente relee todo en cada turno: 30 turnos ≈ 1 hora de lectura en el Mac, ~5,5 min en el servidor.*

Video «Mac Studio vs NVIDIA RTX», oct 2026 · mediciones de MacStories y de la comunidad, con modelos similares pero no idénticos

# Concepto 4 · Caché KV: la memoria de cada conversación

UNA TARJETA RTX PRO 6000 · 96 GB




**32 KB**
por token de contexto (8 bits)

**→ 1,86 millones**
de tokens caben en los 59 GB

**→ ≈ 14 agentes**
con 128.000 tokens cada uno, a la vez

### Si no cabe

El agente falla o hay que recortar su contexto, que es como borrarle la memoria.

### Caché de prefijos

Si el inicio de la conversación no cambió, no se vuelve a leer: 98% en el caso de las 111 horas.

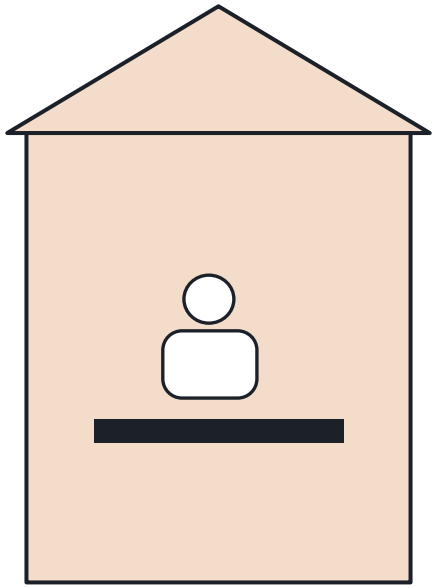
### DeepSeek la comprime

Un millón de tokens en menos de 1 GB, contra ~800 GB en un transformer estándar del mismo tamaño.

*La capacidad es la condición previa: no se puede atender en paralelo lo que no cabe en memoria.*

Video «Mac Studio vs NVIDIA RTX», oct 2026 · capacidad teórica, no rendimiento · DeepSeek: video «What Would it Cost…», oct 2026

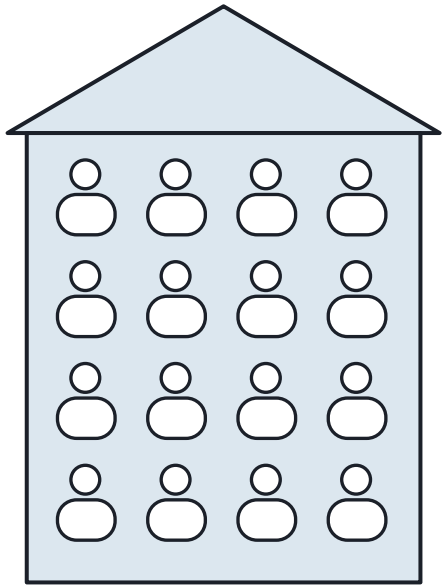
# Concepto 5 · Uno o muchos: la biblioteca



MAC

## Un edificio enorme, un solo escritorio

Cabe un libro gigante (un modelo grande), pero atiende a una persona por vez. Con 3 solicitudes simultáneas, el rendimiento total sube solo 1,23×.



SERVIDOR GPU

## Una biblioteca con muchos escritorios

En cada paso, los pesos se leen una sola vez y cada usuario recibe su token: atender a 32 cuesta casi lo mismo que a uno (batching).

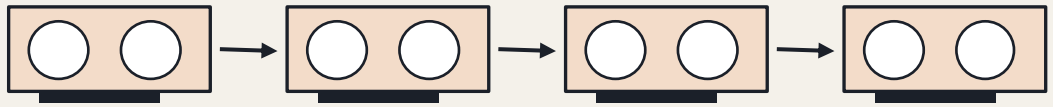
**Mac:** ¿qué tan grande puede ser el modelo?

**GPU:** ¿cuántos agentes a la vez?

Analogía y mediciones: video «Mac Studio vs NVIDIA RTX», oct 2026 (Mac Studio M5 Ultra medido por MacStories)

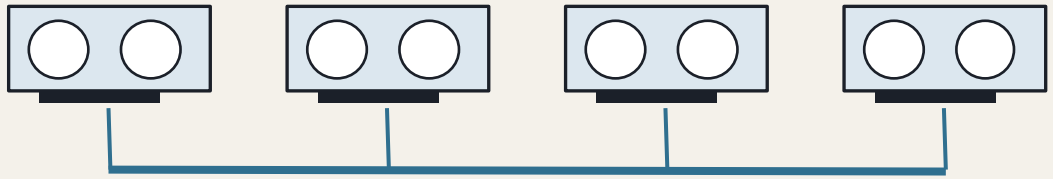
# Concepto 6 · Varias GPU: relevo o trabajo en equipo

**POR CAPAS (PIPELINE)**

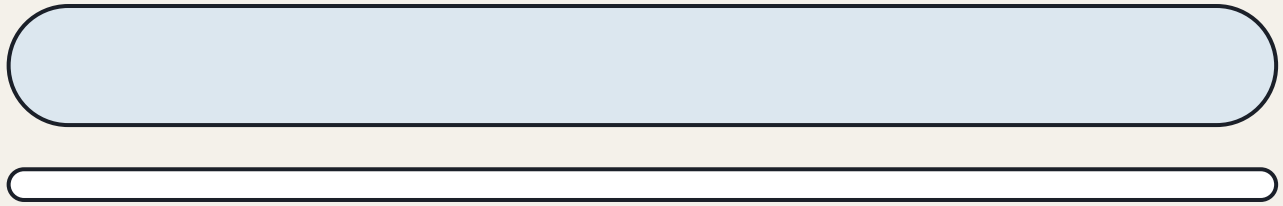


Cada tarjeta espera a la anterior. 4× RTX 3090: ~70 tok/s con una, ~90–97 con dos o con cuatro.

**PARALELISMO DE TENSORES**



Todas trabajan en cada capa y se sincronizan después de cada una (all-reduce): manda el canal entre tarjetas.



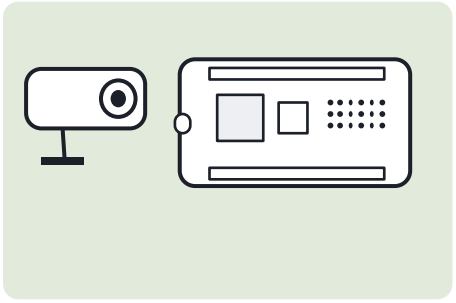
**900 GB/s** NVLink 4 (H100, data center)

**64 GB/s** por dirección · PCIe 5.0 x16

*Sobre PCIe, cuatro tarjetas es un límite razonable. La RTX 5090 no permite comunicación directa entre tarjetas: muy buena sola, mala para escalar.*

Video «Mac Studio vs NVIDIA RTX», oct 2026 · foros de NVIDIA (P2P en GeForce RTX 50)

# Cuatro capas, una regla: el dato decide dónde trabaja la IA



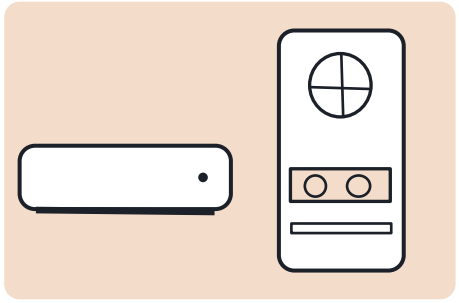
1 · BORDE

**Qwen3.5 0.8B / 2B**

en Arduino UNO Q

Cámaras y sensores, sin internet

~US$79 por punto



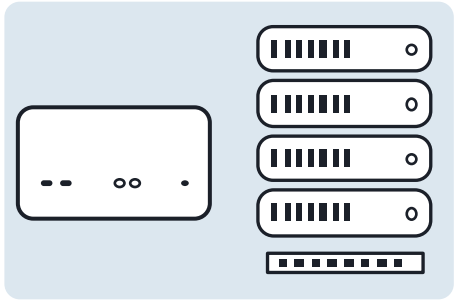
2 · LOCAL

**Qwen3.8 27B**

en un Mac o PC con GPU

Código y datos sensibles

Costo fijo: energía



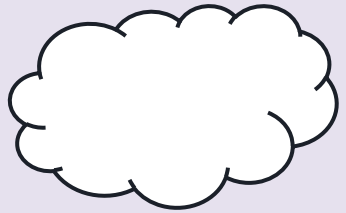
3 · ABIERTO GRANDE

**DeepSeek V4.1 Flash**

en casa o vía API

Lo masivo y los agentes

~US$0,26 por tarea



4 · FRONTERA

**Claude Opus 5.5**

vía API, por excepción

Lo complejo y ocasional

~US$6 por tarea

← más control y privacidad

más capacidad y más costo por uso →

Costos por tarea: Artificial Analysis, oct 2026 · UNO Q: precio de lista en EE.UU.

# Todo pasa por un orquestador

Un gateway de IA con reglas de la empresa entre las personas y los modelos




*Una sola interfaz, compatible con OpenAI: cambiar de modelo es cambiar una regla, no reescribir aplicaciones.*

# Primero, clasificar los datos

Qué capa puede recibir cada clase de dato

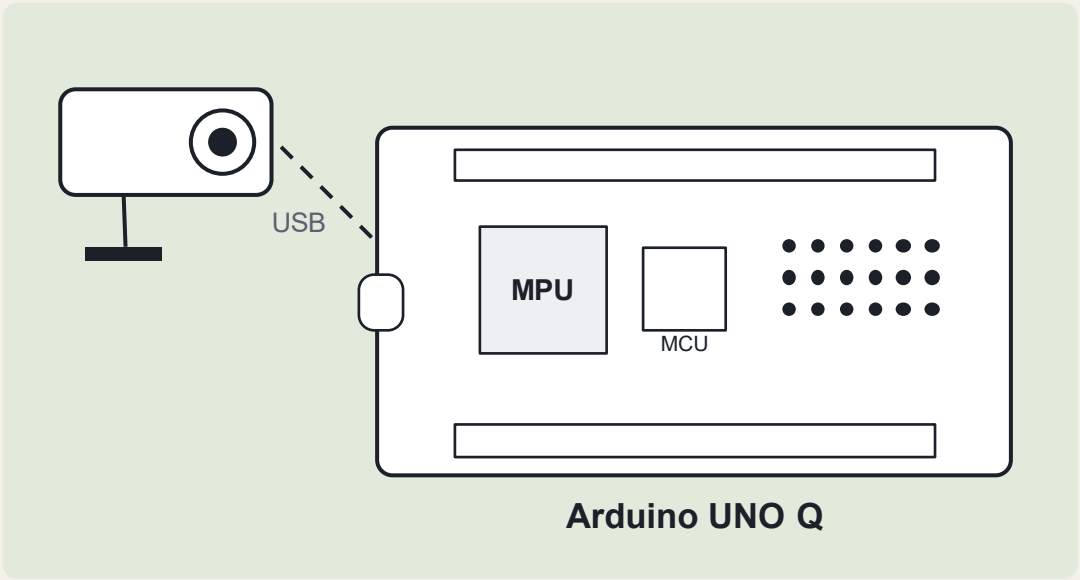
| Capa | **Confidencial**<br>código propio, clientes, RR.HH., contratos, video de personas | **Interno**<br>manuales, correos de trabajo, catálogos | **Público**<br>web, normas, documentos publicados |
|---|---|---|---|
| **Borde · UNO Q** | **Sí** | **Sí** | **Sí** |
| **Local · Qwen3.8 27B** | **Sí** | **Sí** | **Sí** |
| **DeepSeek V4.1 Flash local** | **Sí** | **Sí** | **Sí** |
| **DeepSeek · API (China)** | **No** | **Con cautela** | **Sí** |
| **DeepSeek · API sin retención** | **Con contrato** | **Sí** | **Sí** |
| **Frontera vía API** | **No** | **Con contrato** | **Sí** |

DeepSeek es un modelo abierto: lo sirven decenas de proveedores, en China, EE.UU. y otros países. Elija según dónde procesa cada uno y qué hace con sus datos; con la Ley 21.719, cada envío de datos personales debe poder justificarse.

Clasificación sugerida: adáptela a la política de su empresa y a la asesoría legal

# Capa 1 · Borde: una UNO Q mira la cámara

Arduino UNO Q + cámara USB + Qwen3.5 0.8B o 2B, sin internet




| | |
|---|---|
| Linux (Debian) + MCU STM32 | 2–4 GB de RAM |
| Modelo en 4 bits: ~0,5–1,2 GB | Sin internet · ~US$79 |

1. **Captura**
   La cámara USB toma imágenes del portón, la bodega o el estacionamiento.
2. **Filtra**
   Un detector liviano (por ejemplo, de movimiento) descarta los cuadros sin cambios.
3. **Describe**
   Qwen3.5 mira el cuadro y lo pone en palabras: «persona junto al portón, 23:14».
4. **Avisa**
   El MCU enciende una luz o un relé; la placa envía el evento al orquestador.

*No es video en tiempo real: el modelo mira un cuadro cuando algo cambia, y tarda minutos.*

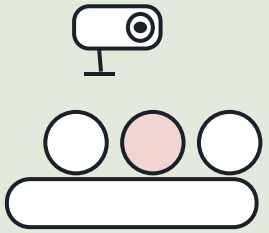
UNO Q: Qualcomm Dragonwing QRB2210 + STM32U585 · tamaño del modelo ≈ 0,56 GB por mil millones de parámetros en 4 bits

# Capa 1 · Otros casos en el borde



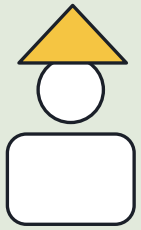
## Medidores análogos

Una foto del manómetro o del medidor de agua se convierte en un número, sin enviar la imagen.



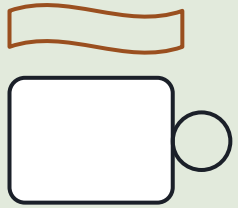
## Conteo y calidad

Contar fruta o detectar defectos en la línea de packing, junto a la cinta.



## Seguridad industrial

¿Lleva casco y chaleco? Aviso antes de entrar a una zona de riesgo.



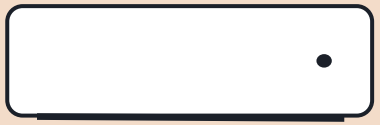
## Mantención

Un sensor de vibración y el modelo explican en palabras que algo anda mal.

*Regla del borde: el video y los datos crudos no salen del lugar; solo salen eventos de texto.*

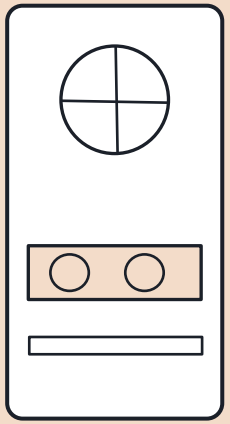
# Capa 2 · Local: Qwen3.8 27B para código y datos sensibles

PARA UNA PERSONA



Mac de 32–64 GB

*o*



PC con RTX 5090 (32 GB)

**34**

puntos en el índice: más que la frontera de feb 2026 (Opus 4.6: 32)

**~16–18 GB**

de memoria en 4 bits

**Apache 2.0**

uso comercial libre

### Para qué

- Asistente de código dentro del editor
- Revisión de código propietario
- Búsqueda en contratos y documentos de RR.HH.
- Agentes con herramientas internas

**Modelo**
Qwen3.8 27B

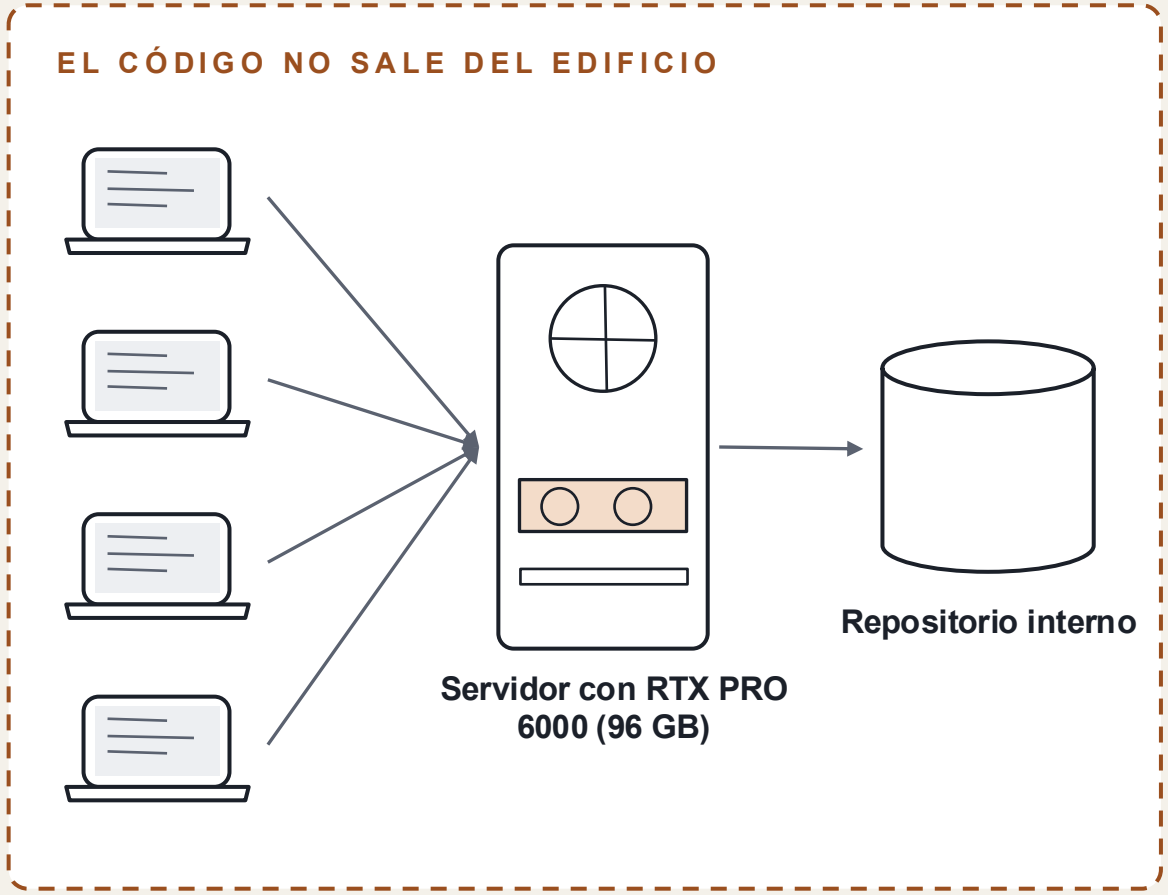
**Motor**
llama.cpp · MLX · vLLM

**API local**
compatible con OpenAI

**Harness**
código, documentos, agentes

Índice: Artificial Analysis v4.3.2, oct 2026 · memoria y hardware: Anexo B de la charla «IA abierta y local»

# Capa 2 · Un servidor para el equipo de desarrollo




**1**

## Mac para uno, GPU para muchos

Una tarjeta de 96 GB carga Qwen en 8 bits y deja caché para ~14 agentes con contextos largos.

**2**

## Medir con varios agentes

Un agente rápido no garantiza cinco: mida tokens por segundo con 1, 4 y 8 agentes a la vez.

**3**

## Congelar la versión

En casa, el modelo no cambia sin aviso; en una API, el nombre de DeepSeek V4 Flash ya apunta a la 4.1.

*Una cocina con un solo chef: un segundo pedido no trae un segundo chef.*

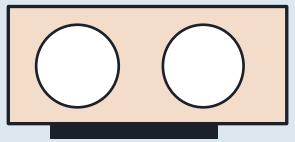
# Capa 2 · ¿Mac o servidor GPU?



## Mac Studio M5 Ultra

96 GB · US$5.499 · 1,2 TB/s · ≤480 W

- ~3× más barato por GB de memoria
- Silencioso, cabe en un escritorio
- Un enchufe normal
- Conserva su valor de reventa
- Ideal: una persona, modelos grandes



## RTX PRO 6000

96 GB · US$16.000 de lista, solo la tarjeta · 1,79 TB/s · 300 W (Max-Q)

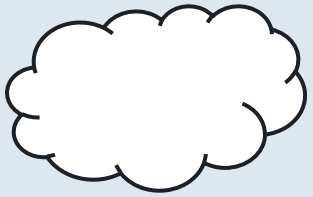
- Lee 100.000 tokens en ~11 s con 4 tarjetas (Mac: ~100 s)
- 30 o más usuarios a la vez
- Caché KV para ~14 agentes por tarjeta
- Paralelismo de tensores con P2P
- 4 tarjetas Max-Q en un solo circuito

*Nada de esto aparece en una tabla de dólares por gigabyte: el Mac mide tamaño; la GPU, concurrencia.*

Video «Mac Studio vs NVIDIA RTX», oct 2026 · precios de lista en EE.UU. · cifras de lectura con modelos similares, no idénticos

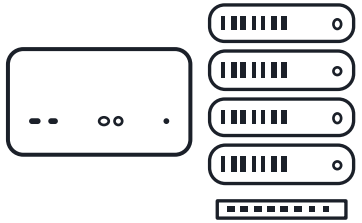
# Capa 3 · DeepSeek V4.1 Flash: ¿vía API o en casa?

Índice 45 · licencia MIT · 552 mil millones de parámetros, 16 mil millones activos



## Vía API

| | |
|---|---|
| **COSTO** | ~US$0,26 por tarea · ~US$19 por día de agentes intensivos |
| **VELOCIDAD** | ~60–220 tok/s por agente, según proveedor |
| **DATOS** | Van al proveedor que usted elija, en China u otros países |
| **DISPONIBILIDAD** | API de DeepSeek: caída de ~5 h el 15 oct · con varios proveedores: 99,9% |



## En casa

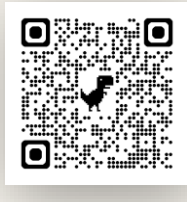
| | |
|---|---|
| **COSTO** | Mac Studio 512 GB usado: ~US$17–23 mil · 4× Spark: ~US$29 mil |
| **VELOCIDAD** | 35–90 tok/s con 1 agente · ~15 tok/s c/u con 16 |
| **DATOS** | No salen de la empresa |
| **DISPONIBILIDAD** | Depende de su equipo técnico |

*Empiece por la API para lo no sensible; compre hardware solo si los datos no pueden salir o si un equipo lo mantiene ocupado todo el día.*

Artificial Analysis (costo por tarea) · OpenRouter (velocidad y disponibilidad por proveedor) · mediciones de la comunidad, oct 2026

# Capa 3 · Vía API no significa vía China

DeepSeek V4.1 Flash 1017 en OpenRouter: un modelo abierto, servido por 20 proveedores



**Orquestador** →

## OpenRouter

Una API, muchos proveedores; si uno falla, pasa al siguiente

**Regla de ejemplo: solo proveedores sin retención de datos y en países aprobados**

→

| | |
|---|---|
| **Together** | **Baseten** |
| **Fireworks** | **DeepInfra** |
| **Cloudflare** | **Crusoe** |
| **Parasail** | DeepSeek · excluido |
| Alibaba Cloud · excluido | SiliconFlow · excluido |

… y otros diez

**20**

proveedores sirven el mismo modelo

**US$0,07–0,30**

por millón de tokens de entrada, según proveedor (salida: US$0,18–1,20)

**99,93%**

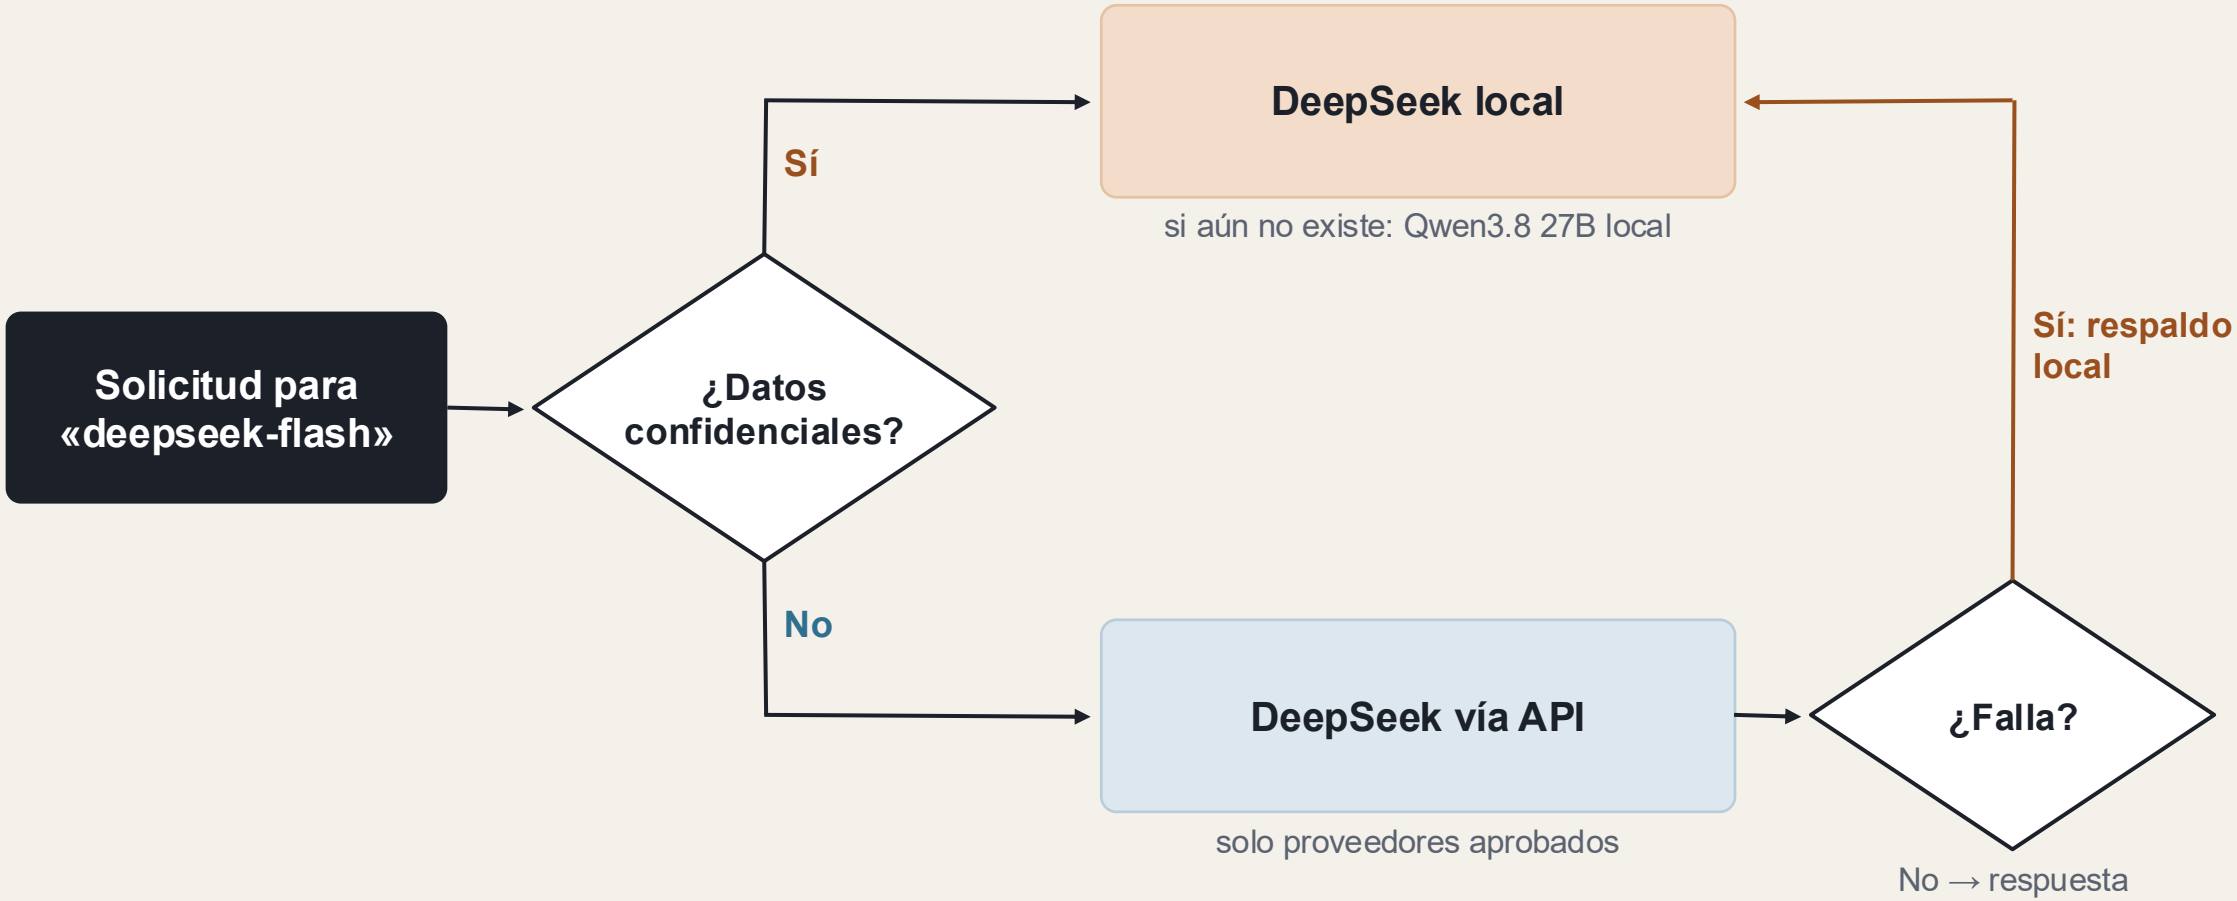
de disponibilidad en 3 días con enrutamiento, contra 92,45% sin él

*Abierto significa poder elegir también quién lo sirve y bajo qué reglas.*

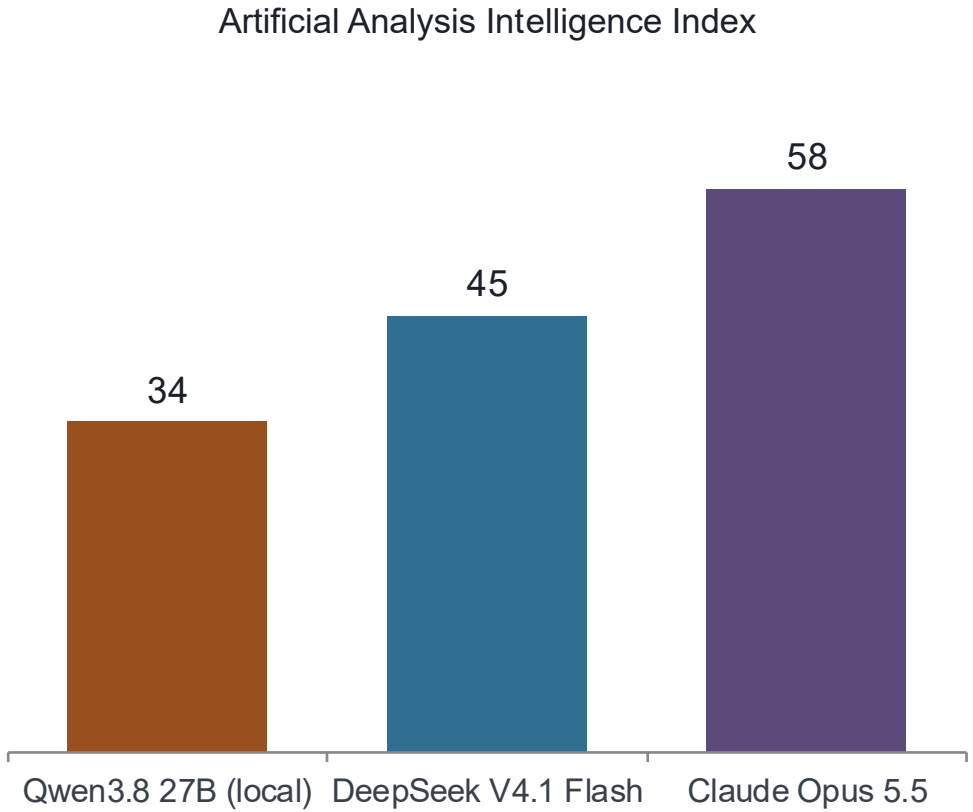
OpenRouter, página de proveedores del modelo, 20 oct 2026 · la regla es un ejemplo: verifique la política de datos y el país de cada proveedor

# Capa 3 · Un modelo, dos caminos, una sola configuración

El orquestador decide en cada solicitud; quien la envía no ve la diferencia



# Capa 4 · Frontera: por excepción y con presupuesto




**US$5,98**

por tarea, contra US$0,26 de DeepSeek: ~23×

**95 tok/s**

contra ~209 de DeepSeek vía API

### Úsela para

- Estudios estratégicos y due diligence
- Arquitectura de sistemas y código difícil
- Revisión final de documentos clave

TRES REGLAS

**Nunca con datos confidenciales · tope mensual de gasto · registro de cada uso**

Artificial Analysis, Intelligence Index v4.3.2, oct 2026 · costo por tarea y velocidad medidos en la API de cada proveedor

# El orquestador: reglas simples, escritas por la empresa

| Si la solicitud… | …va a |
|---|---|
| Trae video o imágenes de cámaras | **Borde (UNO Q): solo sale el evento** |
| Trae código propietario o datos confidenciales | **Qwen3.8 27B local (o DeepSeek local)** |
| Es masiva y no sensible: clasificar, resumir, extraer | **DeepSeek vía API, con proveedores aprobados** |
| Es compleja, ocasional y sin datos sensibles | **Frontera, con tope de gasto** |
| Encuentra un proveedor caído | **La siguiente opción abierta** |

**GATEWAY**

LiteLLM u otro gateway abierto

**MOTORES**

llama.cpp · MLX · vLLM · SGLang

**REVISIÓN**

Las personas revisan las reglas cada mes, con los datos de uso

# Un ejemplo con números: una empresa de 50 personas

| Componente | Cant. | Costo aprox. | Para qué |
|---|---|---|---|
| **Arduino UNO Q + cámara USB** | 8 | ~US$900 | Portones, bodegas, estacionamiento |
| **Piloto: Mac de 64 GB o PC con RTX 5090** | 1 | ~US$2.700–6.000 | Qwen3.8 27B para 1–3 personas |
| **Equipo: servidor con 1× RTX PRO 6000** | 1 | ~US$20.000 | Qwen3.8 27B para ~14 agentes con contexto largo |
| **Mini PC para el orquestador** | 1 | ~US$800 | Reglas, registros y tablero |
| **DeepSeek V4.1 Flash vía API** | — | ~US$19 por día de uso intenso | Lo masivo, no sensible |
| **Frontera vía API** | — | Tope, p. ej., US$500/mes | Lo complejo y ocasional |
| **Opcional: 4× DGX Spark + switch** | 1 | ~US$29.000 | DeepSeek en casa, si los datos no pueden salir |

PILOTO

US$4,5–8 mil

sin servidores grandes, más el uso de las API

CON SERVIDOR

~US$22–28 mil

sin la opción DGX Spark

Valores aproximados en EE.UU., oct 2026, sin IVA ni importación · cámara USB estimada en ~US$30 · RTX PRO 6000 a precio de lista (US$16.000) más un computador estimado en ~US$4.000 · DeepSeek: caso de 111 horas de agentes de código

# Plan de implementación en 90 días

**SEM 1–2**

### Inventario y reglas

- Usos de IA que ya existen
- Clasificación de datos
- Reglas iniciales y elección del gateway

**SEM 3–6**

### Piloto local

- Qwen3.8 27B con 3–5 desarrolladores
- Medir velocidad y calidad
- Caché activa y medida

**SEM 5–8**

### Piloto en el borde

- 2 UNO Q en cámaras reales
- Contar alarmas verdaderas y falsas
- Ajustar el filtro previo

**SEM 7–12**

### API y frontera

- DeepSeek vía API para lo masivo
- Frontera con tope de gasto
- Tablero de costos; decidir hardware grande

**Mida desde el día uno:** costo por tarea · tiempo por tarea · % de solicitudes que no salen de la empresa

# Riesgos y controles

### 1 Origen y licencia

Qwen: Apache 2.0; DeepSeek: MIT. Pesos solo desde la fuente oficial, con verificación de archivos.

### 2 Calidad

Evalúe con casos reales de la empresa; las versiones muy comprimidas pierden precisión.

### 3 Operación

Alguien actualiza, monitorea y revisa que la caché funcione.

### 4 Datos en las API

Cada proveedor procesa en un país y con una política distinta: la clasificación de datos decide.

### 5 Seguridad del agente

Permisos mínimos y aprobación humana para las acciones riesgosas.

### 6 Concurrencia

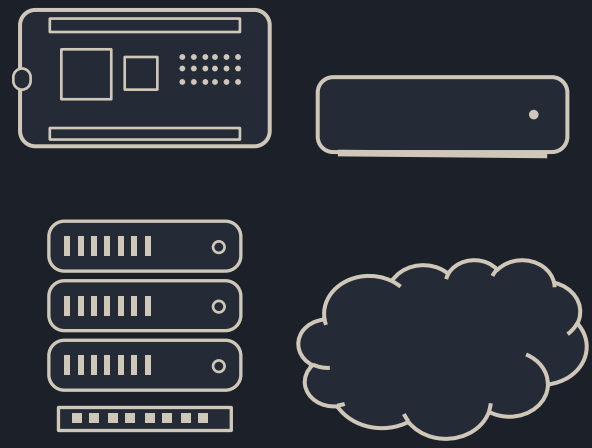
Lo que funciona con un agente puede ahogarse con dieciséis: mida antes de comprar.

*Lo abierto no elimina el riesgo: lo cambia por riesgos que la empresa puede gestionar.*

PARA CERRAR

# Abierto por defecto, frontera por excepción

- El borde mira y avisa, sin internet
- Lo local protege el código y los datos sensibles
- DeepSeek, en casa o vía API, hace el trabajo pesado
- La frontera, solo cuando lo justifica



*Si su proveedor de IA se apaga el lunes, el martes su empresa sigue funcionando.*

Marcelo José Rovai · mjrovai.com